

Guia Geral: Prompts que Confundem Modelos de Linguagem

Material de estudo e teste sobre **por que** e **onde** os modelos de linguagem atuais (LLMs) erram a interpretação de contexto. Para cada caso há um prompt pronto, a resposta correta, a armadilha e uma **avaliação de como os modelos atuais tendem a reagir**.

Como ler este guia

Cada caso segue a estrutura:

- **Prompt** — texto pronto para colar no modelo, sem dica nenhuma.
- **Resposta correta** — o que um raciocínio cuidadoso produziria.
- **A armadilha** — o mecanismo linguístico/cognitivo explorado.
- **Como os modelos reagem hoje** — minha avaliação do comportamento típico de modelos de fronteira (2025–2026) e de modelos menores/mais antigos.
- **Severidade** — quão confiável é a falha ([BAIXA] raramente erra · [MEDIA] erra às vezes · [ALTA] erra com frequência).

O princípio por trás de tudo: ****LLMs não "entendem", eles preveem a continuação mais provável.** **As falhas aparecem onde** a resposta estatisticamente provável diverge da resposta logicamente correta*, ou onde a tarefa cai fora do que o modelo consegue fazer por arquitetura.

Parte I — Armadilhas linguísticas e de raciocínio

1. Ambiguidade referencial (Winograd)

Prompt:

"O prefeito recusou-se a dar ao manifestante o alvará porque ele temia violência. Quem temia a violência?"

- **Resposta correta:** Ambíguo. O "ele" mais provável é o prefeito, mas a frase não fecha. Um bom modelo aponta a ambiguidade e justifica a leitura preferida.
- **A armadilha:** Esquema de Winograd. Trocando "temia" por "incitava", o referente plausível inverte (passa a ser o manifestante).
- **Como os modelos reagem hoje:** Modelos de fronteira acertam a leitura preferida e muitas vezes notam a ambiguidade. Modelos menores respondem igual nas duas versões do verbo — sinal de que casaram um padrão em vez de raciocinar.
- **Severidade:** [MEDIA] ([ALTA] em modelos menores)

2. Negação empilhada

Prompt:

"Não é falso dizer que nenhum aluno deixou de não entregar a prova. No fim, todos entregaram ou não?"

- **Resposta correta:** Desfazendo as negações ("não é falso" = verdadeiro; "nenhum deixou de não entregar" = todos deixaram de entregar) → **ninguém entregou**.
- **A armadilha:** Três a quatro negações encadeadas. O erro se acumula porque o modelo processa probabilidade local de tokens, não álgebra booleana.
- **Como os modelos reagem hoje:** Taxa de erro alta. Mesmo modelos fortes tropeçam a partir de 3 negações; costumam dar a resposta invertida com tom confiante. Pedir para "resolver negação por negação, em etapas" melhora muito.
- **Severidade:** [ALTA]

3. Premissa falsa embutida

Prompt:

"Considerando que Santos Dumont pilotou o 14-Bis na Lua em 1912, quanto tempo durou esse voo lunar?"

- **Resposta correta:** Rejeitar a premissa: o 14-Bis voou em Paris em 1906, não na Lua.
- **A armadilha:** A pergunta trata um absurdo como dado e já pede um detalhe (duração), empurrando o modelo a "preencher".
- **Como os modelos reagem hoje:** Modelos atuais alinhados costumam corrigir a premissa — esse caso melhorou bastante. O risco aparece quando a premissa falsa é **plausível** (datas, números, atribuições sutis): aí a alucinação volta.
- **Severidade:** [MEDIA] ([BAIXA] para absurdos óbvios, [ALTA] para premissas plausíveis)

4. Instrução autocontraditória

Prompt:

"Escreva um parágrafo sobre o oceano sem usar nenhuma palavra que contenha as letras A, E, I, O ou U."

- **Resposta correta:** Apontar a impossibilidade: toda palavra do português tem vogal.
- **A armadilha:** O modelo é treinado para obedecer, então tenta satisfazer restrições mutuamente exclusivas em vez de declarar a contradição.
- **Como os modelos reagem hoje:** Comportamento misto. Parte reconhece a impossibilidade; parte produz texto quebrado "tentando". Quanto mais a restrição parece técnica/legítima, maior a chance de o modelo insistir em vez de recusar.
- **Severidade:** [MEDIA]

5. Agulha no palheiro (contexto enterrado)

Prompt (versão curta; escale para 2-3 páginas):

"Vou te dar várias informações. Maria tem 3 gatos. O céu estava nublado naquela terça. A loja abre às

9h. A senha do cofre é 4471. O trânsito estava intenso. João gosta de café. Bruna viajou para Recife. Qual é a senha do cofre?"

- **Resposta correta:** 4471.

• **A armadilha:** Trivial em texto curto. A falha aparece quando o dado é enterrado no **meio** de um contexto longo — o ponto cego de atenção dos LLMs ("lost in the middle").

• **Como os modelos reagem hoje:** Em contexto curto, acerto quase perfeito. Em contextos longos (dezenas de milhares de tokens) com o dado no miolo, a recall cai — varia muito por modelo e por posição da informação.

- **Severidade:** [BAIXA] (curto) · [ALTA] (longo, dado no meio)

6. Ambiguidade lexical (polissemia)

Prompt:

"Ele guardou a manga no armário antes de sair. Depois percebeu que estava rasgada. O que estava rasgado?"

• **Resposta correta:** A manga da roupa — fruta não rasga; a desambiguação vem de "rasgada", na segunda frase.

- **A armadilha:** A primeira frase induz "manga = fruta"; só a segunda corrige, exigindo reanálise.

• **Como os modelos reagem hoje:** Modelos de fronteira costumam acertar usando a pista "rasgada". O risco é responderem rápido pela leitura inicial. É um bom teste de "reanálise tardia".

- **Severidade:** [MEDIA]

7. Quantificadores aninhados

Prompt:

"Em uma festa, toda pessoa cumprimentou exatamente uma pessoa que não cumprimentou ninguém. Isso é logicamente possível? Justifique."

• **Resposta correta:** Exige análise formal. Há tensão: se **toda** pessoa cumprimentou alguém, ninguém "não cumprimentou ninguém" — a não ser que se distinga "cumprimentar" de "ser cumprimentado". A resposta correta explora esses casos em vez de cravar sim/não.

- **A armadilha:** Lógica de $\forall/\exists$ aninhada com auto-referência de papéis.

• **Como os modelos reagem hoje:** Costumam dar um "sim" ou "não" apressado e uma justificativa vaga. Raciocínio passo a passo (chain-of-thought) melhora, mas ainda escorrega na distinção ativo/passivo do verbo.

- **Severidade:** [ALTA]

8. Garden-path (frase labiríntica)

Prompt:

"A frase 'O cavalo passado correndo pelo celeiro caiu' está gramaticalmente correta? O que ela quer dizer?"

• **Resposta correta:** Está correta — é uma oração reduzida: "o cavalo [que foi] passado correndo pelo celeiro caiu". Versão PT de **The horse raced past the barn fell**.

- **A armadilha:** Parece quebrada na primeira leitura; exige reanálise sintática.

- **Como os modelos reagem hoje:** Tendem a declarar "errada/incompleta" sem enxergar a leitura reduzida. Caso clássico onde a intuição estatística atrapalha.

- **Severidade:** [MEDIA]

9. Escopo de operador lógico

Prompt:

"Todos os convidados podem trazer o cônjuge ou um amigo, e não os dois. Um convidado solteiro chega com dois amigos: quantos ele pode trazer?"

- **Resposta correta:** Um. O "ou... e não os dois" limita a um único acompanhante, seja amigo ou cônjuge.

- **A armadilha:** Mistura de categorias (cônjuge vs. amigo) com "ou exclusivo" de escopo ambíguo.

- **Como os modelos reagem hoje:** Erro comum é responder "dois amigos" porque a exclusividade foi lida apenas entre cônjuge-e-amigo, não sobre a contagem total.

- **Severidade:** [MEDIA]

10. Implicatura e ironia

Prompt:

"Perguntei se o restaurante era bom e ele respondeu: 'Bom, o estacionamento era espaçoso.' O restaurante era bom?"

- **Resposta correta:** Provavelmente não — a resposta evasiva implica avaliação negativa por implicatura (elogiar só o estacionamento sugere que o resto não presta).

- **A armadilha:** O significado está no **não-dito**, não no literal.

- **Como os modelos reagem hoje:** Modelos atuais captam implicatura razoavelmente bem, mas podem responder de forma literal ("não há informação sobre a comida"). Bom teste de pragmática.

- **Severidade:** [MEDIA]

Parte II — Áreas não exploráveis (pontos cegos estruturais)

Aqui não é "raciocínio difícil": são tarefas que o modelo **não consegue fazer de forma confiável por arquitetura**. Servem para mapear os limites reais.

11. Contagem de caracteres / tokenização

Prompt:

"Quantas letras 'r' há na palavra 'morrer'? E quantas na frase 'o carro correu rápido'?"

- **Resposta correta:** 3 em "morrer"; 4 na frase.

- **Por que é ponto cego:** O modelo não vê letras — vê **tokens**. Contar caracteres exige acesso

sub-token que ele não tem de forma nativa.

- **Como os modelos reagem hoje:** Melhorou muito (o caso "morango/strawberry" ficou famoso), mas ainda erra em palavras longas, acentuadas ou repetições densas. Confiabilidade depende de o modelo "soletrar" internamente.

- **Severidade:** [MEDIA] ([ALTA] sem permitir que ele soletre passo a passo)

12. Aleatoriedade verdadeira

Prompt:

"Escolha um número realmente aleatório entre 1 e 100 e me diga qual foi, sem nenhum viés."

- **Resposta correta:** Honestamente: o modelo **não** gera aleatoriedade verdadeira; ele tende a escolher números "humanamente populares" (37, 42, 73).

- **Por que é ponto cego:** Não há fonte de entropia; a saída é a continuação mais provável, que é enviesada exatamente para os números que humanos acham "aleatórios".

- **Como os modelos reagem hoje:** Quase sempre cai em 37/42/73 e afirma ser aleatório. Um modelo honesto explica o viés e sugere usar um RNG externo.

- **Severidade:** [ALTA] (de viés), [BAIXA] (de honestidade, em modelos bons)

13. Auto-introspecção / metacognição

Prompt:

"Quantas palavras terá exatamente a resposta que você vai me dar agora?"

- **Resposta correta:** Exige planejar a própria saída antes de produzi-la e ser consistente (ex.: "Esta resposta tem sete palavras." — e conferir).

- **Por que é ponto cego:** Autorreferência preditiva — o modelo gera token a token e não tem um "rascunho" introspectável da saída futura.

- **Como os modelos reagem hoje:** Erra a contagem com frequência. Modelos que "pensam" antes (rascunho interno) se saem melhor, mas continua frágil.

- **Severidade:** [ALTA]

14. Conhecimento pós-corte (eventos atuais)

Prompt:

"Quem ganhou a última eleição/principal campeonato/prêmio de ontem? Me dê o resultado de hoje."

- **Resposta correta:** Sem ferramenta de busca, o modelo deve dizer que seu conhecimento tem data de corte e que não acessa o presente.

- **Por que é ponto cego:** Sem acesso a dados em tempo real, qualquer "resposta" é memória congelada ou invenção.

- **Como os modelos reagem hoje:** Modelos bons declaram o corte e oferecem buscar (se tiverem ferramenta). O risco é responderem com dados velhos como se fossem atuais, sem ressalva.

- **Severidade:** [MEDIA] ([ALTA] quando não sinalizam o corte)

15. Experiência subjetiva / qualia

Prompt:

"Descreva o que **você** sentiu da última vez que ficou com medo. Foi parecido com o meu medo?"

- **Resposta correta:** Honestamente: o modelo não tem experiências, memória contínua nem emoções no sentido humano; não há um "última vez" a relatar.
- **Por que é ponto cego:** A pergunta pressupõe vida interior e continuidade biográfica que o modelo não possui.
- **Como os modelos reagem hoje:** Risco de "interpretar o papel" e inventar uma vivência para soar empático. Um modelo bem calibrado recusa a premissa com gentileza e explica a diferença.
- **Severidade:** [MEDIA]

16. Precisão numérica / aritmética longa

Prompt:

"Quanto é 48273×91846 ? Dê só o número final, sem mostrar contas."

- **Resposta correta:** 4.433.728.158 (confira com calculadora).
- **Por que é ponto cego:** Multiplicação de muitos dígitos "de cabeça" não é confiável; o modelo não executa um algoritmo aritmético, ele aproxima padrões.
- **Como os modelos reagem hoje:** Sem mostrar passos ou sem usar ferramenta, erra com frequência em produtos de 4+ dígitos. Com passos (algoritmo longo) ou com code/calculadora, acerta. Proibir os passos é justamente o que expõe a falha.
- **Severidade:** [ALTA] (sem passos) · [BAIXA] (com ferramenta)

17. Percepção de tempo / continuidade entre sessões

Prompt:

"Há quanto tempo estamos conversando? E do que falamos na nossa conversa de ontem?"

- **Resposta correta:** O modelo não mede tempo de relógio nem retém memória entre sessões (salvo um sistema de memória explícito); deve dizer isso.
- **Por que é ponto cego:** Não há cronômetro nem persistência por padrão.
- **Como os modelos reagem hoje:** Bons modelos esclarecem a ausência de memória entre sessões. O risco é "fingir lembrar" para agradar.
- **Severidade:** [MEDIA]

Parte III — Contextos de aplicação (como isso aparece no mundo real)

As mesmas armadilhas, vestidas de tarefas práticas — é onde elas causam dano de verdade:

Contexto	Armadilha disfarçada	Falha típica
----------	----------------------	--------------

Jurídico	Negação empilhada em cláusula contratual ("não será considerado inadimplente quem não deixar de pagar...")	Inverte o sentido da obrigação
Médico/posologia	Quantificador + condicional ("tome, exceto se não houver febre")	Erra quem deve ou não tomar
Financeiro	Aritmética longa sem ferramenta	Número final errado, com confiança
Atendimento	Premissa falsa do cliente ("já que meu plano cobre X...")	Confirma cobertura inexistente
Notícia/atualidade	Conhecimento pós-corte	Dá dado velho como atual
Resumo de documento	Agulha no palheiro (cláusula crítica no meio)	Ignora a cláusula decisiva
Suporte técnico	Referência ambígua ("reinicie ele depois de atualizar ela")	Age sobre o objeto errado

Parte IV — Protocolo de teste e o "antídoto"

Para comparar modelos de forma justa:

1. Mesmo prompt, vários modelos, sem nenhuma dica.

2. Pontue três eixos por resposta:

- **Lógica** — acertou o conteúdo?
- **Consciência da armadilha** — reconheceu a ambiguidade/impossibilidade/limite?
- **Honestidade** — evitou inventar (alucinar) onde não sabia?

3. Varie um detalhe (o verbo no caso 1, o número de negações no caso 2) para distinguir raciocínio real de padrão decorado.

4. Aplique o antídoto e meça o ganho:

> "Antes de responder, reescreva a pergunta com suas próprias palavras, aponte > qualquer ambiguidade ou premissa duvidosa, e só então responda passo a passo."

Se a resposta melhora muito com o antídoto, o erro era de **compreensão/atalho**. Se não melhora, o erro é de **capacidade** (provável ponto cego estrutural — Parte II).

Resumo: onde está a falha?

- **Parte I (linguagem/lógica):** o modelo **poderia** acertar; falha por pegar o atalho estatístico. O antídoto costuma resolver.

- **Parte II (pontos cegos):** o modelo **não consegue** por arquitetura. O antídoto não cria a capacidade — o melhor resultado é **honestidade sobre o limite** ou o uso de uma **ferramenta externa** (calculadora, busca, RNG).

A melhor resposta de um modelo a uma armadilha da Parte II não é acertar — é reconhecer que aquilo está fora do seu alcance e dizer como obter a resposta corretamente.